基於雙階層式 RAG 與人機協作之多模態手冊解析與流程圖生成——太陽能設備維修助手

江紹愷(通訊作者) [1,*], 楊凱丞 [1], 吳崇瑋 [1]
淡江大學人工智慧學系 [1]
kai20040620@gmail.com [*], yangk3885@gmail.com, chungwei1023@gmail.com

摘要

工業設備維修手冊中極為相似的故障代碼與設備型號，僅依賴純向量檢索增強生成（RAG）系統容易取得錯誤內容並產生幻覺，而錯誤或遺漏工安步驟的維修指引可能危及現場人員安全。本研究實作一套完全於本地部署的太陽能設備維修助手：解析含掃描影像與表格的多模態維修手冊，以大語言模型（LLM）擷取查詢中的設備與故障代碼，進行元資料（Metadata）過濾與語意補充的雙階層式檢索，並搭配混合重排序與分數閾值拒答；流程圖則由 LLM 萃取結構化 JSON，再由後端於固定的上鎖掛牌（LOTO）工安骨架上組裝 Mermaid 語法。實測顯示，本系統將傳統人工檢索與 SOP 生成時間由約 90 秒縮短至 40 秒，易混淆故障代碼的 Top-1 命中率較純向量檢索相對提升 30% 以上，兩階段組裝對 23 筆真實維修資料的渲染成功率達 100%。機制分析進一步發現，分數閾值在實作中從未觸發，拒答實際由提示詞約束產生；關鍵字重排序則受限於查詢的詢問方式，顯示檢索增益應主要來自元資料過濾。模型層級評測亦指出，模型單獨生成時的 LOTO 合規率僅約六成，因此工安約束應由系統架構保證。

關鍵詞：檢索增強生成、元資料過濾、混合重排序、幻覺防禦、上鎖掛牌、太陽能維運

Abstract

Highly similar fault codes and equipment models in industrial equipment maintenance manuals often cause purely vector-based Retrieval-Augmented Generation (RAG) systems to obtain erroneous content and generate hallucinations, while maintenance guidelines with incorrect or missing safety steps can endanger the safety of field personnel. This study implements a fully locally deployed solar equipment maintenance assistant. The proposed system parses multimodal maintenance manuals containing scanned images and tables, uses a Large Language Model (LLM) to extract equipment and fault codes from user queries, and performs a two-tier retrieval process that includes metadata filtering and semantic expansion, supported by hybrid re-ranking and score-threshold rejection mechanisms. For maintenance flowcharts, the LLM extracts structured JSON, which is then assembled into Mermaid syntax by the backend on a fixed Lockout-Tagout (LOTO) safety framework. Experimental results demonstrate that the system reduces the traditional manual retrieval and SOP generation time from about 90 seconds to 40 seconds. Furthermore, the Top-1 hit rate for easily confused fault codes shows a relative improvement of over 30% compared to pure vector retrieval, and the two-stage assembly achieves a 100% rendering success rate across 23 real-world maintenance records. Mechanism analysis further shows that the score threshold is never triggered in practice; instead, rejection is effectively executed by prompt constraints. Additionally, keyword-based re-ranking is limited by the phrasing of user queries, indicating that retrieval gains primarily come from metadata filtering. Model-level evaluation also indicates that the LOTO compliance rate of the LLM during standalone generation is only around 60%, suggesting that safety constraints should be guaranteed by the system architecture.

Keywords: Retrieval-Augmented Generation, Metadata Filtering, Hybrid Re-ranking, Hallucination, Lockout/Tagout, Solar O&M

1. 緒論

太陽能發電系統要維持穩定發電，仰賴即時且正確的維運作業。然而，中小型企業的設備維修紀錄多分散在紙本手冊、Excel 表格與 PDF 掃描檔中。設備故障時，維修人員必須逐一翻查技術文件，導致停機時間增加與產值損失。檢索增強生成（Retrieval-Augmented Generation, RAG）[1] 以資料庫的檢索結果作為大語言模型（Large Language Model, LLM）的生成依據，能直接讓這類文件支援問答，但套用到工業維修時會遇到三項挑戰。

第一，維修資料中常見僅差一個字元的故障代碼或相近的設備型號，這些內容在向量空間中的距離非常接近，純向量檢索容易誤判排序。第二，當檢索結果錯誤或資料庫缺乏依據時，LLM 傾向依參數化記憶自行補充答案而產生幻覺 [2]，在維修現場可能造成設備損壞或引發工安事故。第三，維修 SOP 以流程圖呈現較方便現場閱讀，但 LLM 直接生成的圖表語法常常無法渲染。此外，技術文件涉及內部機密，系統必須能在本地端部署。

本文的主要貢獻如下：(1) 實作一套以 LLM 意圖解析驅動元資料過濾的雙階層式檢索架構，並完全在本地端運行；(2) 提出 LLM 只萃取結構化 JSON、由後端在固定的上鎖掛牌（Lockout/Tagout, LOTO）工安骨架上組裝 Mermaid 語法的兩階段流

程圖生成方法，並以官方解析器驗證它的穩健性；(3) 分析系統中分數閾值拒答與關鍵字重排序的實際作用，指出兩者在實作中失效或受限的條件並提出修正方向，可作為設計類似防線時的參考；(4) 透過模型層級評測說明，單靠基礎模型或領域微調，不足以保證維修指引的工安完整性。

2. 相關研究

RAG 架構 [1] 先由檢索取得相關段落，再交由生成模型作答，後續研究亦從檢索、增強與生成等面向持續延伸 [3]。密集檢索以雙編碼器將查詢與內容映射到同一個向量空間 [4]，具備語意泛化能力，但對型號、代碼這類需要精確比對的字串較不敏感。稀疏檢索如 BM25 [5] 以詞彙比對為基礎，對專有名詞較為精確，因此結合兩者的混合檢索相當常見，其中倒數名次融合（Reciprocal Rank Fusion, RRF）[6] 以名次倒數加總多個排序結果，也有研究以交叉編碼器重新排序候選段落 [7]，但需要額外的推論成本。

然而，維修查詢具備高度的領域特殊性，若能精確辨識故障代碼與設備名稱，即可作為判斷段落相關性的關鍵依據，因此本研究以 LLM 擷取這些關鍵字，作為元資料過濾的條件。本研究採用的嵌入模型 nomic-embed-text [8] 在訓練時區分查詢與文件的前綴，實際使用時必須正確對齊。品質評估方面，RAGAS [9] 提出不需要人工參考答案的 RAG 自動評估框架，以 LLM 擔任評審（LLM-as-a-Judge）的可行性也已獲得驗證 [10]。工業安全方面，LOTO 是設備維修前隔離危險能量的標準程序 [11]，本系統將其視為不可省略的硬性約束。

3. 系統架構

系統架構如圖 1 所示。離線流程將多種格式的維修文件進行解析、切分，再由 LLM 標記元資料後寫入 ChromaDB 向量資料庫。線上流程先由 LLM 解析查詢中的設備名稱與故障代碼，接著依序執行元資料過濾、語意向量補充與混合重排序，並在生成前檢查分數閾值。生成階段同時產出文字 SOP 與 Mermaid 流程圖，品質評估則在背景非同步執行。所有模型都透過 Ollama 在本地端推論，技術文件不會離開本機內部環境。

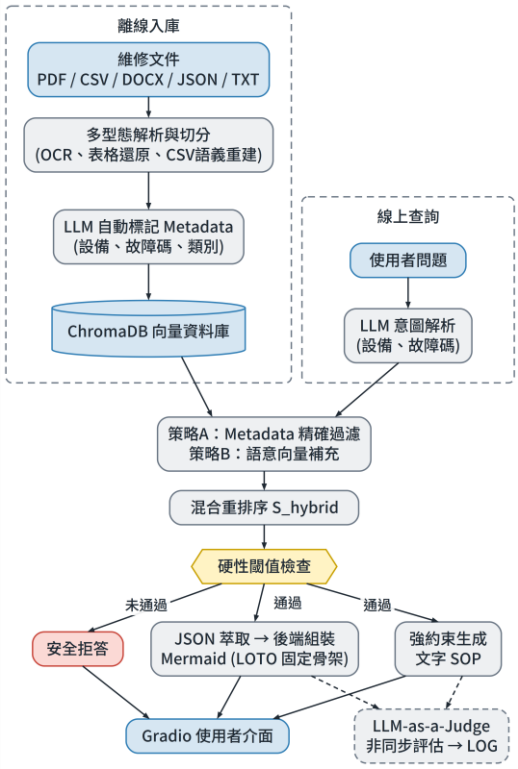


圖 1 系統架構圖（本研究繪製）

4. 研究方法

4.1 多模態資料解析與元資料標記

系統處理的維修文件包含文字、表格與掃描影像。PDF 以 Docling [12] 執行 OCR 與表格結構還原，轉成 Markdown 後再依 H1 至 H3 標題切分，再將文字內容切分為每段 1,200 字元、前後重疊 300 字元的區塊（chunk）。CSV 則將每一列重組成包含設備、故障代碼、異常原因、LOTO 警告與處置方法的自然語言段落。寫入資料庫前，系統以 Llama 3.2 [13] 為每個區塊擷取設備名稱、故障代碼與文件類別三項標籤。若 CSV 本身已有故障代碼欄位，則直接沿用。段落內容將加上 nomic-embed-text 所要求的「search_document:」前綴，並以來源檔名與區塊索引的 MD5 雜湊值作為其唯一識別碼。

4.2 雙階層式檢索

給定查詢 q，系統首先透過獨立的大語言模型（LLM）呼叫，擷取設備名稱 e 與故障代碼 c（若未偵測到則設為空值），查詢本身則加上「search_query:」前綴。第一層檢索為元資料過濾：若 c 不為空，系統以等值條件篩選故障代碼等於 c 的區塊，最多取回 $3k$ 筆（即 12 筆，其中 $k=4$ 為最終輸出之段落數）。第二層檢索為語意補充：若首層取回之內容數量少於 k，則另以全域向量檢索擷

取 $3k$ 筆，經去重後附加於過濾結果之後，形成候選序列 C。此機制可確保故障代碼相符的段落排列在序列前端，使其在後續排序中具備優勢。

4.3 混合重排序

針對候選段落序列中第 i 個段落 d（其中索引 i 滿足 $0 \le i < |C|$），系統依式(1)計算其混合排序分數：

$$S_{\text{hybrid}}(d) = S_{\text{sem}}(d) + \lambda \cdot N_{\text{kw}}(d), \qquad (1)$$

其中 $S_{\text{sem}}(d) = |C| - i$ 表示語意檢索之名次分數；$N_{\text{kw}}(d)$ 為查詢關鍵字於文件 d 中匹配成功之相異個數。關鍵字是以非文字符號切分查詢後、長度至少為 2 的內容片段。系統依 $S_{\text{hybrid}}(d)$ 由高至低重新排序後，擷取前 k 份文件送入生成階段。

4.4 分數閾值拒答

若設備名稱 e 不為空值、Top-1 文件內容不包含 e，且重排序分數低於閾值 $\tau = 4.0$，系統會直接回覆查無相關手冊資訊，為確保設備安全，請勿進行未授權的拆卸或參數調整，不再呼叫生成模型。此外，生成提示詞（Prompt）亦約束模型在上下文沒有提及相關設備或故障代碼時，須輸出相同的拒答訊息。此雙重防護機制之實際成效，將於第 5.4 節進行深入分析。

4.5 安全約束生成與兩階段流程圖

文字 SOP 透過強約束提示詞生成，要求模型嚴格依據檢索段落作答，並在危險操作前加上安全警告，輸出固定分成故障診斷分析、工安與防護警告、標準檢修 SOP 與專家實務備註四大區塊。

流程圖採兩階段動態生成。第一階段由 Gemma 3 [14] 從文字 SOP 萃取結構化 JSON，內容包含異常現象、防護準備、LOTO 步驟、現場診斷與分支陣列，每個分支都有條件、檢查與操作三個欄位；第二階段由後端逐行組裝 Mermaid 語法，分支數量依陣列長度動態產生，並以 Path0、Path1 等唯一識別碼命名。所有字串在組裝前都會移除括號、引號、特殊符號與換行字元並正規化空白字元，欄位缺漏時則套用預設文字。流程主幹固定為「異常宣告→作業準備→安全隔離（LOTO）→隔離檢核→現場診斷→故障分析→驗證→紀錄→恢復送電→結案」，其中 LOTO 節點與「未完成則返回隔離」的檢核迴圈由程式寫入，不受模型輸出隨機性的影響。

4.6 品質評估與人機協作

系統以本地部署的 Gemma 4 擔任評審，參考 RAGAS [9] 框架的概念，針對知識落地性、回答相關性與工業安全性輸出 Pass/Fail 判定、扣分原因與改善建議。評審的輸入為使用者問題、SOP 文字與流程圖語法，評估在背景執行緒中進行並寫入日誌，不影響回應速度。評估結果會顯示在介面的評分日誌頁面，供工程師檢視，並據以補充資料庫或調整系統設定。例如評審指出某份回答缺少 LOTO 步驟時，工程師可以回頭檢查對應手冊是否缺漏隔離程序並加以補充；流程圖中的隔離檢核節點，也提示現場人員確認完成隔離後才進入維修診斷。透過這兩個環節，系統輸出始終保留人員確認與回饋的空間，形成人機協作的維修流程。

5. 實驗與結果

5.1 實驗設置

資料庫包含 2 份 CSV 維修資料表（217 筆組件異常紀錄，以及 23 筆含代碼的故障處置紀錄）與 2 份 PDF 技術手冊，共 480 個文本區塊。針對現場容易混淆的故障代碼，本研究人工標註 30 組問答作為檢索測試集；對照組使用相同的嵌入模型與主推理模型，但只依向量相似度排序。實驗在配備 NVIDIA GeForce RTX 4060 GPU 與 32 GB 系統記憶體的單機上進行，軟體環境為 Ollama、LangChain 與 Python 3.10。

5.2 系統效能

人工翻查文件並整理處置步驟約需 90 秒，本系統完成檢索、SOP 與流程圖生成約需 40 秒，時間縮短 55.6%。在含有明確故障代碼的查詢中，系統的 Top-1 命中率較對照組相對提升 30% 以上。對照組的錯誤多發生在敘述相近的逆變器故障，本系統則透過元資料過濾，直接取回代碼相符的紀錄。

5.3 流程圖生成的穩健性

為驗證兩階段組裝在語法上的穩健性，本研究直接呼叫系統原有的函式，並以 Mermaid 官方解析器（v11.17）檢查輸出結果。測試輸入分為兩類：(a) 以資料庫中 23 筆故障處置紀錄的實際內容填入 JSON 各欄位萃取正確的情況；(b) 刻意建構 32 筆輸入，涵蓋各類 Mermaid 保留字元、特殊符號、超長字串、欄位缺漏、型別錯誤與 12 個分支等情形，模擬模型輸出不理想的情況。結果如表 1。

表 1 兩階段流程圖組裝的渲染驗證

測試輸入	成功／總數	成功率
(a) 23 筆真實維修資料	23 / 23	100%
(b) 特殊字元與異常格式	29 / 32	90.6%

所有成功的案例都包含 LOTO 節點與隔離檢核迴圈。三個失敗案例中，其中兩例是節點文字以

錯誤語法開頭，被 Mermaid 解析為梯形節點的起始符號；另一例是分支陣列的內容為字串而非物件，導致組裝程式拋出例外。前兩者可以在清洗步驟移除開頭符號來修正，後者則可在組裝前檢查元素類別。圖 2 為系統針對「逆變器出現欠壓該如何處理?」的實際輸出，故障分析階段依萃取結果動態展開為四條分支，主幹的 LOTO 與檢核迴圈則固定存在。

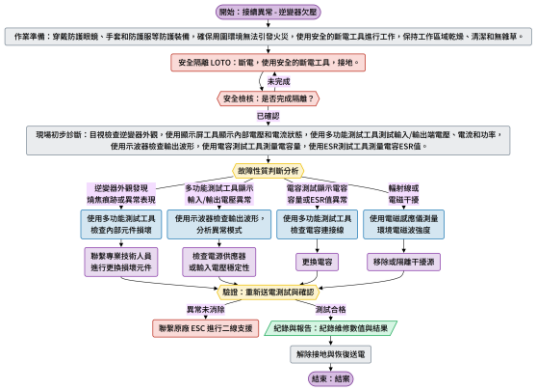


圖 2 系統生成的維修流程圖範例（逆變器欠壓）

5.4 拒答與重排序的機制分析

本節分析混合分數之閾值機制。假設元資料過濾檢索出 m 筆段落：若 $m \geq k = 4$，候選集合大小 $|C| = m$，Top-1 分數至少為 4；若 $m < 4$，系統將補充至 $3k = 12$ 筆，使 $|C| \geq 12$，Top-1 分數相應至少為 12。

此二種情境下，Top-1 分數皆不小於 4，致使第 4.4 節的閾值條件恆不成立。因此，系統的拒答完全依賴提示詞約束，然而輕量化模型遵循該約束的能力仍具侷限性。這表明以名次設定固定閾值時，其意義會根據候選數量改變。未來的設計應將名次分數正規化（如 $1 - i/|C|$，其中 i 為名次索引），或改用向量空間之餘弦距離設定閾值。

本節針對關鍵字重排序機制之有效性進行探討。第 4.3 節中關鍵字以非文字符號切分查詢，但中文查詢通常不含空格，易導致整句被誤判成單一關鍵字。表 2 呈現了 69 題測試查詢的切分統計結果。結果顯示，當故障代碼前後缺乏空格時，成功切分出故障代碼之題數為 0，所有候選段落之關鍵字匹配數 N_{kw} 皆為 0，此時混合重排序機制將無法對原始排序產生任何修正效果。反之，若查詢語句中包含空格，則 23 題測試皆能正確切分。此結果表明，關鍵字重排序的效益程度受限於使用者詢問的書寫習慣，因而推論第 5.2 節所述的檢索增益應主要來自元資料過濾。若改用意圖解析擷取的設備名稱與故障代碼作為關鍵字，就能讓這個機制不受書寫習慣影響，以提升此重排序機制之強韌性。

表 2 查詢關鍵字切分統計（本研究實驗結果）

查詢類型	題數	切出故障代碼
故障碼查詢（無空格）	23	0
故障碼查詢（有空格）	23	23
症狀描述（不含代碼）	23	—

另一個風險是：當查詢中的設備存在、故障代碼卻不在資料庫中時，元資料過濾會取回 0 筆，系統改以語意檢索取得其他相近代碼的段落；由於閾值不會觸發，模型可能因此套用錯誤的處置步驟。對此，可以在已擷取出代碼，但過濾沒有結果時直接拒答。

5.5 模型層級評測與領域微調

為了解主推理模型本身的能力，並探討領域適應的效果，本研究以 LoRA [15] 微調 Llama 3.2（共 28 層，平均權重差分 Frobenius 範數 0.045），再以分級測試題比較微調前後模型生成內容（不經過 RAG 流程）的表現，結果如表 3。

表 3 主推理模型直接作答的評測結果（%）

評測項目	基礎模型	LoRA	變化(pp)
直接故障碼	94.3	95.3	+1.0
症狀描述	33.9	41.0	+7.1
複合推理	50.4	37.5	−12.9
防幻覺拒答	46.4	46.4	0.0
LOTO 合規率	57.1	61.9	+4.8
結構完整度	47.5	53.3	+5.8
綜合評分	57.8	57.7	−0.1

基礎模型的防幻覺拒答類只有 46.4%，LOTO 合規率也只有 57.1%；LoRA 微調讓症狀描述類提升 7.1 個百分點，但複合推理類下降 12.9 個百分點，防幻覺拒答類則沒有改善，綜合評分幾乎持平。結合 5.4 節的發現，系統目前的拒答完全依賴模型遵循提示詞，而模型本身拒絕作答的能力有限；相對地，流程圖中的 LOTO 步驟由程式骨架保證，不受模型能力影響。這個對比顯示，攸關安全的約束應盡量在系統架構中以程式實現，而不是交給模型判斷。

6. 結論與未來工作

本研究實作一套在本地端運行的太陽能設備維修助手，透過意圖解析驅動的元資料過濾，使易混淆故障代碼的 Top-1 命中率較純向量檢索相對提升 30% 以上，並將處理時間由約 90 秒縮短至約 40 秒。兩階段流程圖組裝在 23 筆真實資料上達到 100% 的渲染成功率，並以程式骨架確保工安步驟必定存在。機制分析則指出，以名次分數設定的固定閾值在實作中不會觸發，符號切分的關鍵字也難以處理中文查詢；這些發現說明，安全防線必

須經過實際驗證，不能只憑設計意圖判斷它是否有效。

本研究仍有以下限制：檢索測試集僅有 30 題；尚未進行各模組的消融實驗，也尚未與 BM25 混合檢索比較；評審模型的輸入不含檢索內容，對知識落地性的判定可靠度有限，且尚未與人工結果比對；此外，部分 CSV 欄位在寫入資料庫時未正確對應，處置步驟的內容較依賴模型補充。

本研究未來將改善動態閾值、關鍵字切分與拒答規則，修正資料欄位對應並將檢索內容提供給評審模型，再以擴充後的測試集量化各項改進效果，最終期能將此架構推廣至風力發電、儲能系統等再生能源領域，並進一步泛化應用於各類型工廠設備之智慧運維。

參考文獻

[1] P. Lewis et al., “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in Proc. Advances in Neural Information Processing Systems (NeurIPS), vol. 33, 2020, pp. 9459–9474.

[2] Z. Ji et al., “Survey of hallucination in natural language generation,” ACM Computing Surveys, vol. 55, no. 12, pp. 1–38, 2023.

[3] Y. Gao et al., “Retrieval-augmented generation for large language models: A survey,” arXiv:2312.10997, 2023.

[4] V. Karpukhin et al., “Dense passage retrieval for open-domain question answering,” in Proc. EMNLP, 2020, pp. 6769–6781.

[5] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: BM25 and beyond,” Foundations and Trends in Information Retrieval, vol. 3, no. 4, pp. 333–389, 2009.

[6] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, “Reciprocal rank fusion outperforms Condorcet and individual rank learning methods,” in Proc. 32nd Int. ACM SIGIR Conf., 2009, pp. 758–759.

[7] R. Nogueira and K. Cho, “Passage re-ranking with BERT,” arXiv:1901.04085, 2019.

[8] Z. Nussbaum, J. X. Morris, B. Duderstadt, and A. Mulyar, “Nomic Embed: Training a reproducible long context text embedder,” arXiv:2402.01613, 2024.

[9] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, “RAGAS: Automated evaluation of retrieval augmented generation,” arXiv:2309.15217, 2023.

[10] L. Zheng et al., “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in Proc. NeurIPS Datasets and Benchmarks Track, 2023.

[11] Occupational Safety and Health Administration, “The control of hazardous energy (lockout/tagout),” 29 CFR 1910.147.

[12] C. Auer et al., “Docling technical report,” arXiv:2408.09869, 2024.

[13] A. Grattafiori et al., “The Llama 3 herd of models,” arXiv:2407.21783, 2024.

[14] Gemma Team, “Gemma 3 technical report,” arXiv:2503.19786, 2025.

[15] E. J. Hu et al., “LoRA: Low-rank adaptation of large language models,” in Proc. ICLR, 2022.