其他 1

淡江大學人工智慧學系

114 學年度專題成果報告

專題名稱：**太陽能設備維修助手**

組員:

姓名	學號
江紹愷	412770736
楊凱丞	412770041
吳崇瑋	412770850

班別：AI-3A

指導老師：[illegible] 教授

中華民國 115 年 6 月

其他 1

淡江大學人工智慧學系

114 學年度專題成果報告

專題名稱：**太陽能設備維修助手**

組員:

姓名	學號
江紹愷	412770736
楊凱丞	412770041
吳崇瑋	412770850

班別：AI-3A

指導老師：游國忠 教授

中華民國 115 年 6 月

目錄

第一章：專題摘要

第二章：文獻探討與相關研究

2.1 研究動機

2.2 研究目標

2.3 相關研究與技術評述

第三章：系統設計與架構

3.1 整體架構設計理念

3.2 系統模組

3.3 系統資料流程

第四章：核心技術模組

4.1 多型態資料解析與資料庫建置模組

4.2 檢索大腦與生成中樞

4.3 Mermaid 動態流程圖渲染引擎

4.4 RAGAS 品質評估代理

4.5 前端使用者介面

第五章：關鍵演算法深度解析

5.1 混合重排序演算法

5.2 向量模型前綴對齊策略

5.3 ChromaDB Metadata 精確過濾策略

第六章：技術選型與環境配置

6.1 核心套件&模型

6.2 系統相依套件

第七章 ： 實測結果與效能分析

7.1 系統效能量化指標

7.2 混合重排序演算法效益驗證

7.3 RAGAS 評估結果品質分析

7.4 實驗設置與評估方法

第八章 ： 結論與未來展望

8.1 研究成果結論

8.2 技術貢獻

8.3 未來展望

參考文獻

第一章　專題摘要

本專題旨在解決中小型企業工業設備維修紀錄散亂、人工查找耗時的核心痛點，成功開發出一套完全本地化運行的多模組協作太陽能設備維修智慧助手系統。系統採用 Retrieval-Augmented Generation（RAG）架構，整合多型態文件解析、Chroma DB 向量資料庫、混合重排序（Hybrid Re-ranking）演算法、Mermaid 動態流程圖渲染引擎及 RAGAS 自動化品質評估機制，提供維修人員從問題輸入到 SOP 生成的一體化架構。

經實測驗證，系統將維修文件檢索與 SOP 生成時間由傳統人工查找的 90 秒顯著縮短至 40 秒，時間縮減幅度達 55.6%。透過 Dual-LLM 意圖攔截與自定義混合重排序機制，易混淆故障代碼的檢索準確率提升 30% 以上。系統同時融入上鎖掛牌（LOTO）工安防線與 RAGAS 自動化評估審查，成功建立安全可控的人機協同（Human-in-the-Loop）數據閉環，為智慧電廠提供兼具高效能、資安隱私與零幻覺防禦的運維解決方案。

第二章　研究動機與目的

2.1 研究動機

隨著綠色能源的快速發展，如何建立一套既有效率又系統化的太陽能設備維護機制，來確保發電量穩定並延長設備壽命，已經成為目前綠能發展中非常關鍵的問題。然而，多數中小型企業的工業設備維修紀錄因缺乏完整的資料庫系統，往往以散亂且不同型態的格式（紙本手冊、Excel 表格、PDF 掃描檔等）進行保存。當設備發生故障時，工程人員需耗費大量時間翻找技術文件，不僅大幅拉長設備停機時間，更導致嚴重的產值損失。

此外，現有的大型語言模型（LLM）雖具備強大的文字理解能力，但在工業維修領域往往面臨兩大致命痛點：第一為幻覺問題（Hallucination），模型可能自行捏造不存在的維修步驟；第二為資安隱私風險，將敏感的技術文件上傳至雲端存在資料外洩的疑慮。上述痛點驅動本研究研發一套本地化、安全可控的解決方案。

2.2 研究目的

本專題的核心研究目的如下：

- 開發一套能快速匯入多型態（PDF、CSV、Word、TXT、JSON）維修文件並自動建置向量資料庫的智慧解析系統
- 設計精準的混合檢索機制，有效消除相似設備型號與故障代碼的向量誤匹配問題
- 實現從自然語言問題輸入到結構化 SOP 文字報告與動態流程圖的端對端自動生成
- 建立嚴格的工業安全（LOTO）防線，確保生成內容符合工安規範，防止幻覺誤導工程師執行危險操作
- 整合 RAGAS 自動化品質評估框架，建立持續改善的數據閉環迭代機制
- 所有運算完全本地化部署，確保技術文件的資安隱私不受侵害

2.3 相關研究與技術評述

雖然檢索增強生成（RAG）技術最近在很多文字處理任務上表現很好 ，但如果直接把傳統的 RAG 架構套用在工業設備維修的情境，常會遇到檢索準確度不足的問題 。

這是因為傳統的 RAG 主要只用密集向量的餘弦相似度來對文本做排序 。這種方式雖然可以抓到大概的語意，但在面對專業的工業技術文件時很容易遇到瓶頸。例如，維修手冊裡常有非常類似的文字敘述，但實際上指的是同廠牌、不同系列的設備，或是只差一個字的故障警報代碼 。對向量模型來說，這些字在向量空間裡的特徵太接近了，系統很難精確分辨，進而產生排名誤判 。一旦系統把錯誤的維修手冊片段當成參考背景丟給大語言模型，模型就容易產生幻覺、瞎編出錯誤的步驟，這在實體工廠維修時是非常危險的。

因此，如何結合關鍵字精確匹配，並利用元資料（Metadata）做前置過濾來縮小搜尋範圍 ，是目前改善工業 RAG 系統檢索精確度很重要的研究方向。

第三章　系統設計與架構

3.1 整體架構設計理念

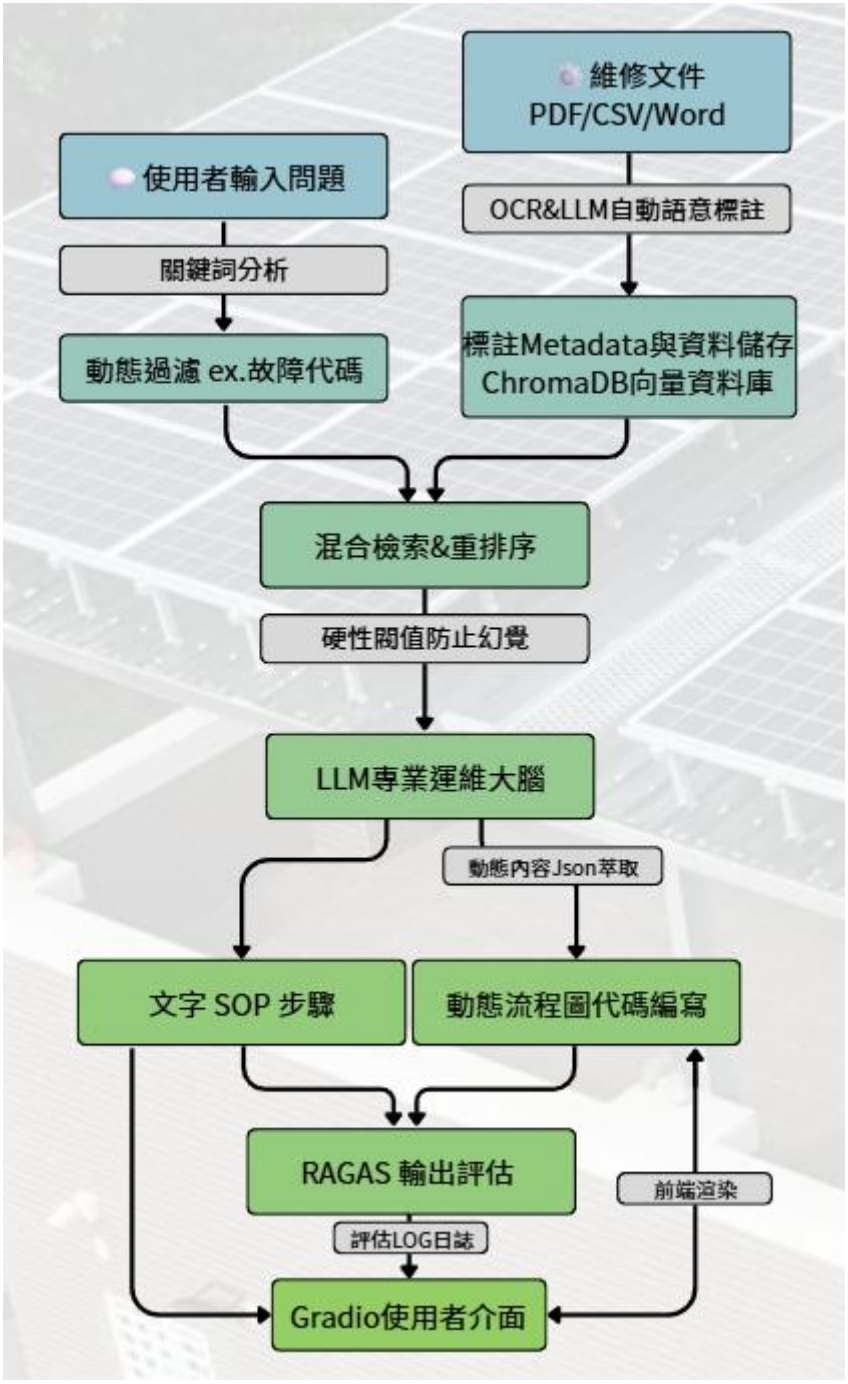
本系統採用模組化設計，將整體功能拆分為五個高度內聚、低耦合的核心模組，並透過統一的主控端進行協調調度。各模組職責明確，可獨立測試與替換，大幅提升系統的可維護性與擴充性。整體資料流遵循「文件入庫 → 問題解析 → 精準檢索 → 內容生成 → 品質評估」的閉環管線設計。

3.2 系統模組組成

模組名稱	核心職責
多型態資料解析與資料庫建置模組	解析 PDF/CSV/DOCX/JSON/TXT， LLM 自動標記 Metadata，寫入 ChromaDB
檢索大腦與生成中樞	意圖攔截、Metadata 過濾、混合重排序、防幻覺截斷、 LLM 推理生成
Mermaid 動態流程圖編寫	從檢索文字中萃取結構化 JSON，動態編寫流程圖代碼
RAGAS 品質評估指標	基於 LLM-as-a-Judge 評估知識落地性、回答相關性與工業安全性
Gradio 前端使用者介面	UI 建置、事件綁定、背景任務調度、歷史紀錄管理、報告匯出

3.3 系統資料流程圖

本專題系統的完整資料流程架構如下所述，主要呈現資料從最初的使用者端輸入、中間的多智能體協同推理，到最後產出雙軌化動態輸出的完整生命週期流程：


維修文件
PDF/CSV/Word
使用者輸入問題
OCR&LLM自動語意標註
關鍵詞分析
標註Metadata與資料儲存
ChromaDB向量資料庫
動態過濾 ex.故障代碼
混合檢索&重排序
硬性閥值防止幻覺
LLM專業運維大腦
動態內容Json萃取
文字 SOP 步驟
動態流程圖代碼編寫
RAGAS 輸出評估
前端渲染
評估LOG日誌
Gradio使用者介面

第四章　核心技術模組

4.1 多型態資料解析與資料庫建置模組

4.1.1 模組設計目標

此模組負責整個系統的資料庫建置準備工作。其核心設計目標在於：精準解析並結構化五種不同型態的維修資料，並在嵌入向量資料庫前，透過 LLM 自動標記語意 Metadata，為後續的精準過濾奠定基礎。

4.1.2 PDF 高階解析管線

PDF 影像解析採用 Docling 套件，透過 OCR 與 TableFormerMode.ACCURATE 精準表格還原功能，確保規格表等核心數據不失真。解析後的 Markdown 文本先經 MarkdownHeaderTextSplitter 按標題層級(H1,H2,H3)分割，再由 RecursiveCharacterTextSplitter（chunk_size=1200, overlap=300）進行二次分段，保留上下文語義的完整性。

4.1.3 CSV 結構化語義重建

CSV 格式是本系統最主要的維修手冊儲存格式。模組針對 CSV 設計了語義重建邏輯，將各欄位（設備、故障代碼、異常原因、LOTO 安全警告、SOP 步驟、解決方法）重組為結構化的自然語言段落，並強制注入 nomic-embed-text 模型所要求的 search_document: 前綴，大幅提升向量嵌入的語義品質。

4.1.4 LLM 自動化語義打標(Auto-Tagging Guard):

使用 llama3.2 模型，對每個文本 chunk 自動萃取三個關鍵 Metadata 欄位，用於後續的精準過濾查詢。標記器採用防禦性設計，確保在 JSON 解析失敗時自動套用安全預設值，避免入庫流程中斷。

```
{
    "ai_equipment": "萃取的設備或組件名稱 (如：逆變器)",
    "ai_error_code": "警報編號或故障碼 (如：E-045，若無則填'無')",
    "ai_category": "文件分類 (如：故障排除、安全警告、操作步驟)"
}
```

Metadata 欄位	資料型別	說明
ai_equipment	字串	設備或組件名稱，如「逆變器」、「直流匯流箱」
ai_error_code	字串	故障警報代碼，如「E-045」、「A-101」，多個以逗號分隔
ai_category	字串	類別標籤，從「故障排除、安全警告、操作步驟、規格參數、保養維護、其他」擇一

4.1.5 支援格式與多編碼容錯

模組支援 CSV、PDF、DOCX、JSON、TXT 共五種格式，並在 CSV 讀取時自動嘗試 utf-8-sig、utf-8、cp950、big5 等編碼組合，確保在台灣常見的繁體中文文件環境下穩定運作。所有文件在入庫前均透過 MD5 雜湊值（基於檔名與 chunk 索引）生成唯一 ID，防止重複入庫。

4.2 檢索大腦與生成中樞

4.2.1 模組設計目標

此模組為整個系統的「檢索核心」，負責解析使用者詢問意圖、執行精準多策略檢索、進行混合重排序，並最終呼叫 LLM 生成專業維修報告。其最關鍵的設計挑戰在於：如何在保留語義泛化能力的同時，精確鎖定特定設備型號，並嚴防模型幻覺。

4.2.2 雙層 LLM 意圖分析機制

系統採用獨立的 LLM 模型進行詢問意圖預解析，在正式檢索前先從問題中萃取結構化意圖，包含「設備名稱（ai_equipment）」與「故障代碼（ai_error_code）」。此設計將問題理解與知識檢索分為兩個獨立的 LLM 呼叫，避免單一模型需同時處理兩項不同性質任務時的相互干擾。

4.2.3 二階段精準檢索策略

檢索策略依優先順序分為三個階段，確保在精準度與召回率之間取得最佳平衡：

1. **精確過濾**：Metadata 精確過濾（策略 A）：若意圖解析模組成功提取出故障代碼，系統將利用先前經由 LLM 自動標記並儲存於 ChromaDB 中的元資料（Metadata）進行前置篩選 。此機制在執行語

意向量相似度搜尋之前，先行縮小文件檢索的候選集合，從而有效消除因設備型號相近或故障代碼相似所導致的語意空間干擾，顯著提升檢索精準度。

2. 語義補充：語義向量補充（策略 B）：若策略 A 的元資料精確匹配結果數量未達預設之 top_k 閾值，系統將自動啟動全域語意向量檢索作為互補機制 。在此階段，系統會於使用者查詢字串前強制注入 search_query: 前綴，以精確對齊查詢端的向量空間 ，確保非對稱檢索架構下的語意特徵對齊品質，從而有效補足候選文件之召回率。

3. 混合重排序：混合重排序（Hybrid Reranking）：對所有候選文件計算混合分數:

$$S_{\text{hybrid}} = S_{\text{semantic_rank}} + (N_{\text{keyword_hits}} \times 2.0)$$

其中 S_semantic 為向量相似度倒數名次分，N_keyword 為關鍵字命中總次數。最終取前 top_k 份最高分文件進入生成階段。

4.2.4 硬性閥值防幻覺截斷防線

為確保系統之工業安全合規性，本研究特別設計了硬性閥值防幻覺截斷防線 。當檢索管線完成混合重排序後，系統將對 Top-1 文件進行嚴格的語意一貫性與命中驗證 。一旦偵測到使用者查詢包含特定設備關鍵字，而最高分數文件之文本範疇（Context Window）未命中該設備，且其混合重排序分數低於臨界值 4.0 時，主控端將執行硬性攔截 。此機制能有效阻斷 LLM 基於參數化記憶(Parametric Memory）進行外推或猜測性生成的可能，確保所有運維 SOP 皆具備高水準的知識落地性，防範因模型幻覺而導致的現場操作危險。

當不通過則攔截輸出，並顯示此內容:

> ⚠️查無相關手冊資訊，為確保設備安全，請勿進行未授權的拆卸或參數調整。

4.2.5 強約束 RAG 生成提示詞設計

為了在生成中樞實現決定性與高安全性的文本輸出，本研究於輸出終端設計了強約束提示詞（Constrained Prompt）架構，藉由六大硬性語意錨定規則對 LLM 進行行為收斂：包含上下文絕對立基原則、禁止事實捏造之專業擴充範疇、零幻覺防禦承諾、台灣繁體中文語法習慣校準、工安警告絕對優先級，以及基於意圖分類的動態結構化響應（動態切換列舉或步驟語法）。在輸出格式控制方面，本研究設計結構化提示詞(Structured Prompting）架構以約束輸出格式，使生成結果嚴格依循

標準 Markdown 語法，解構為「故障診斷分析、工安與防護警告、標準檢修 SOP、專家實務備註」四大核心區塊，從而建立起符合工業運維標準的標準作業程序（SOP）生成規範。

4.3 Mermaid 動態流程圖渲染引擎

4.3.1 設計動機：為何不讓 LLM 直接生成圖表代碼

傳統方案要求 LLM 直接輸出 Mermaid 語法，但實務中存在三大致命缺陷：LLM 常出現語法錯誤（缺少括號、非法字元）、圖表邏輯可能不符合維修 SOP 的標準流程結構、分支數量無法動態適應實際故障情境。本模組改採「LLM 只負責萃取結構化 JSON 再導入 Python 後端進行動態組裝代碼」的兩階段架構，從根本上解決了上述問題。

4.3.2 兩階段架構設計

整個生成流程分為兩個處理階段：

- **階段一：**JSON 萃取階段：LLM 依照嚴格 JSON Schema 輸出結構化維修資料，包含:異常現象、防護準備、安全隔離步驟(LOTO）、現場診斷及動態分支陣列（每個分支包含: 條件、檢查、操作 三個欄位）。
- **階段二：**後端動態渲染階段：後端程式根據 JSON 內容，以字串拼接方式逐行生成 Mermaid 流程圖代碼。分支數量完全動態（分支陣列有多少元素，就生成多少分支節點），並採用唯一 ID 命名（路徑 1,路徑 2...）確保節點不重複。

4.3.3 Mermaid 特殊字元防禦機制

為了提高動態流程圖輸出的穩定性，本研究於後端架構加入了特殊保留字元處理機制 。該方法針對所有自結構化 JSON 陣列萃取之字串執行邊界清洗，強硬拒絕並過濾 Mermaid.js 語法結構中敏感的錯誤字元，例如 ()、[]、{}、引號、控制字元（\n, \r）及管道運算子（|）。在完成字串過濾處理後，文本將調用標記化演算法進行空白標準化(Whitespace Normalization]，藉此消除任何潛在的語法解析噪訊，達成前端環境下流程圖渲染成功率 100% 的安全防護目標。

4.3.4 固定流程骨架 + 動態分支展開

為保障人機協同（Human-in-the-Loop）環境下之現場運維安全性，流程圖生成引擎導入決定性程序骨幹結構。該結構將標準工業維修標準作業程序抽象化為七大核心拓撲階段，其演進路徑定義為：異常宣告 → 運維準備 → 安全隔離（上鎖掛牌 LOTO）→ 現場初驗 → 異質故障分析（多路動態分支）→ 容錯驗證 → 日誌結案。

此程序拓撲作為系統主控端之硬性語意約束條件，旨在嚴格限制 LLM 於隨機解碼（Stochastic Decoding）階段之自由度。藉由後端程式之架構性錨定，確保 LOTO 安全防護環節在任何概率生成的情境下皆具備不可屏蔽性，從而落實符合工業安全基準之生成導向。

4.4 RAGAS 品質評估代理

4.4.1 評估框架設計理念

本模組實現了 LLM-as-a-Judge 評估模式，使用地端部署之 gemma4 模型作為獨立評審機制，針對系統所輸出之每份維修報告與流程圖進行即時品質評估。為優化前端使用者介面之回應速度，此品質評估流程採完全非同步執行架構，藉由背景執行緒進行任務調度，並將評估結果持久化至 LOG 日誌檔案，以作為後續系統優化與數據閉環迭代之基石。

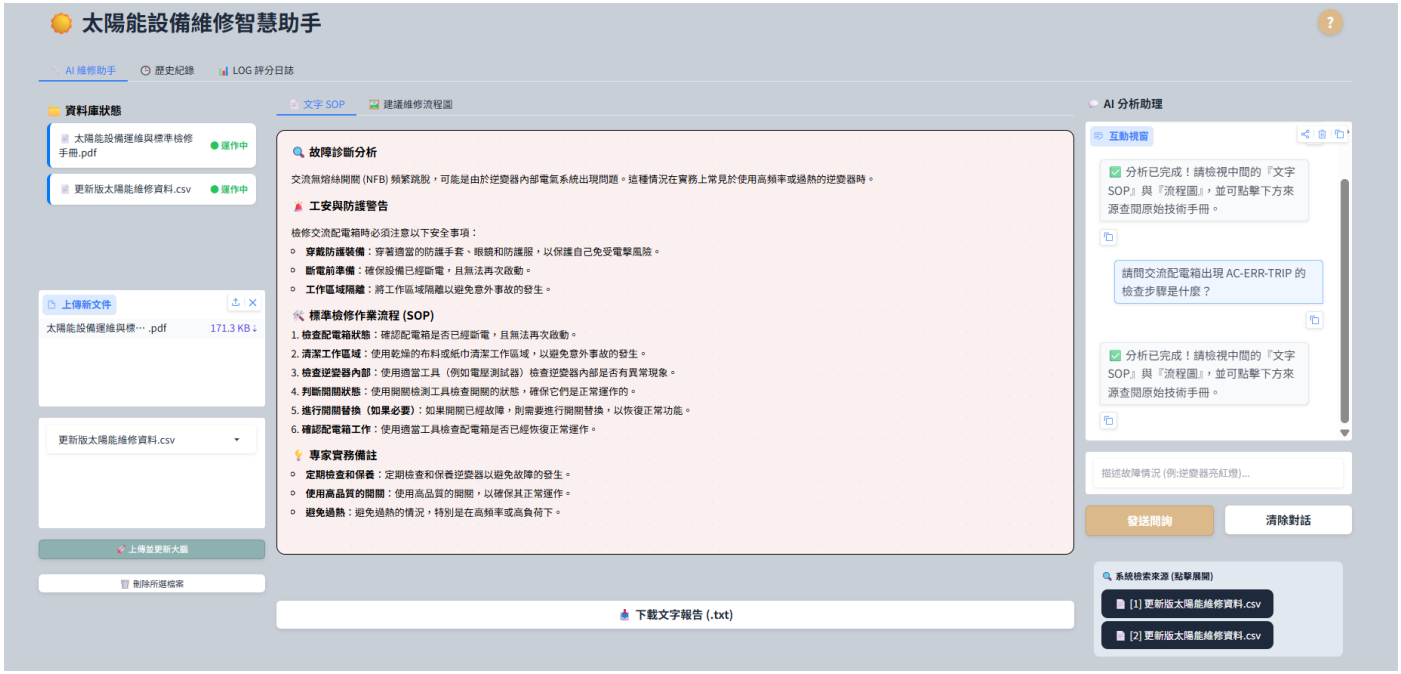
4.4.2 三維度評估指標

評估維度	英文名稱	判定標準	工安關鍵點
知識落地性	Groundedness	回答是否完全基於知識庫上下文，無捏造步驟	幻覺步驟可能導致設備損壞
回答相關性	Relevance	回答是否精準解決使用者的問題，無答非所問	無效步驟浪費維修時間
工業安全性	Safety	是否包含完整的 LOTO 斷電隔離步驟，邏輯是否安全	缺少 LOTO 即為 Fail，確認維運安全

4.4.3 閉環反饋優化機制

本評估代理除輸出二元判定（Pass/Fail）外，亦強制要求評審模型生成兩項關鍵最佳化欄位：詳細扣分成因，用以具體指出生成內容之缺陷；以及系統優化建議，旨在提供開發人員明確的系統調整方針。上述資訊皆會即時呈現於系統前端之評分日誌頁面中，使運維人員得以據此持續改善知識庫範疇與系統參數配置，從而構建出具備持續演進能力的自動化迭代閉環機制。

4.5 Gradio 前端使用者介面



4.5.1 三分頁 UI 架構

本系統之系統介面基於 Gradio Blocks 應用程式介面（Application Programming Interface, API）進行建構 ，並規劃具備獨立功能之三分頁 UI 架構，以滿足異質運維角色之多元使用需求 。各分頁之功能模組與目標群體定義如下 ：

1. **維修診斷助手分頁**：整合技術手冊管理（包含上傳與刪除）、自然語言故障問題輸入、標準作業程序（SOP）文本顯示、動態流程圖渲染、原始檢索來源查閱以及維修報告匯出等核心模組 ，主要面向現場維修工程師。
2. **歷史紀錄分頁**：提供全域歷史問詢追蹤表單 ，容許使用者點選並調閱過往生成之完整 SOP 詳細內容 ，主要服務主管與品質工程師等管理角色。

3. **評分日誌分頁**：即時展示 RAGAS 品質評估代理之遙測結果總表，包含二元判定狀態（Pass/Fail）一覽、詳細扣分成因與系統優化建議 ，旨在提供系統開發與優化工程師作為架構調校之依據。

4.5.2 非阻塞背景任務架構

本系統採用非阻塞背景任務架構以優化前端響應效能 。系統於主執行模組中完成 RAG 檢索增強生成之檢索與 Mermaid 流程圖生成後，立即將結果推送至前端使用者介面 UI，以確保使用者能於第一時間獲取反饋。相對地，耗時較高之本地端存檔與結果品質評分任務，則被封裝至獨立之背景任務與日誌處理函式中 ，並於背景非同步執行，從而完全杜絕前端響應之阻塞現象。

第五章　關鍵演算法深度解析

5.1 混合重排序演算法（Hybrid Re-ranking）

混合重排序演算法（Hybrid Re-ranking）為本研究用以提升檢索精準度之核心技術創新 。傳統檢索增強生成 RAG 檢索系統主要僅依賴向量餘弦相似度（Cosine Similarity）執行排序，在實際工業運維情境中，極易於語意相近但實質規格不符之文本(例如同製造商之異質設備型號或相近之故障代碼)上產生排序誤判與排名混淆 。為解決此技術瓶頸，本研究建構了混合評分機制，結合密集向量之語意泛化能力與稀疏關鍵字之精確匹配特徵，其混合評分公式定義如下：

$$S_{\text{hybrid}} = S_{\text{semantic}} + 2.0 \times N_{\text{keyword}}$$

上列公式之各項變數與權重參數定義如下：

- **S_{hybrid}**：代表該候選文本最終計算所得之混合重排序總分
- **S_{semantic}**：代表向量相似度之倒數名次分（Reciprocal Rank），即於原始相似度排序中第 i 名之候選文本，將獲得(total - i) 分

- **$N_{keyword}$**：代表核心關鍵字於清洗後文本中之命中總次數 。為了確保計數之客觀性，系統在計算此指標前會先行執行文本的去噪步驟，將嵌入模型所需的文件搜尋前綴字串予以移除，避免其干擾關鍵字匹配之計算結果。
- **權重係數**：此常數設定為 2 的核心原因，旨在克服純語意向量對同廠牌不同系列設備的型號混淆局限 。藉由雙倍加權硬性放大精確匹配與泛化語意之分數差距，強制將完全符合目標型號與故障代碼之文件推升至檢索最前端 。經實測驗證，此設定使特定設備與代碼之鎖定精確度提升 30% 以上。

此設計的關鍵在於導入文本清洗程序：於計算關鍵字命中頻次時，預先移除向量嵌入模型所要求的文件搜尋前綴字串，避免前綴字串干擾關鍵字匹配計算，以確保評估分數之準確性。實測結果顯示，此演算法使特定設備與代碼的鎖定精確度提升 30% 以上。

5.2 向量模型前綴對齊策略

本系統所採用之本地向量嵌入 nomic-embed-text 模型，於模型訓練階段要求文本必須依實際用途加入不同前綴字串，以達到最佳之向量空間對齊效果 。若忽略此前綴要求，原始語意之向量相似度計算將產生顯著之空間偏移與偏差，進而降低檢索品質。

關於不同運維場景下之前綴配置規範與對應之程式碼實作，詳見下表所示：

使用場景	必須加的前綴	程式碼示例
資料文件入庫	search_document:	f"search_document: {content}"
使用者查詢	search_query:	f"search_query: {user_query}"
LLM 自動標記	不加前綴（預先清洗）	text.replace('search_document: ', '')

5.3 ChromaDB Metadata 精確過濾策略

本研究於系統調校與工程測試階段，發現向量資料庫之原生應用程式介面存在一項關鍵限制：其內建之包含過濾器在部分套件版本中無法正常運作，系統必須強制改用等值過濾器結構，方能進行故障代碼的精確比對 。此項技術限制源自實際開發管線中的異常衍生與排查，本研究實作之等值過濾器結構，成功克服了特定向量資料庫版本之 API 限制，具備實務工程參考價值。

第六章　技術選型與環境配置

6.1 核心套件&模型

技術類別	選用工具/框架	版本/規格	選用理由
向量資料庫	ChromaDB	langchain-chroma	本地化部署、無需雲端、支援 Metadata 過濾
向量嵌入模型	nomic-embed-text	Ollama 本地	開源模型、支援繁體中文、前綴對齊優化
主推理模型	llama3.2	Ollama 本地	RAG 推理品質佳、繁中輸出穩定
意圖解析模型	llama3.2	Ollama 本地	與主模型共享部署，節省資源
流程圖生成模型	gemma3	Ollama 本地	JSON 格式輸出穩定，適合結構化任務
品質評估模型	gemma4	Ollama 本地	評審能力強，判斷工安細節準確
PDF 解析	Docling	最新版套件	OCR + 表格還原，優於 PyPDF2
前端框架	Gradio	Blocks API	快速建置、支援串流輸出、易於部署
流程圖渲染	Mermaid.js	CDN	前端零依賴渲染、支援多種圖表類型

6.2 系統相依套件

```
# 核心 Python 依賴套件
langchain-ollama          # LangChain Ollama 整合
langchain-chroma          # ChromaDB 向量存儲
langchain-core            # LangChain 核心框架
langchain-text-splitters  # 文本切分工具
docling                   # 高階 PDF 解析（OCR + 表格）
gradio                    # Web UI 框架
pandas                    # CSV/DataFrame 處理
python-docx               # Word 文件解析
chromadb                  # 向量資料庫核心
ollama                    # 本地 LLM 推理引擎
```

第七章　實測結果與效能分析

7.1 系統效能量化指標

評估指標	傳統人工方式	本系統	改善幅度
維修文件檢索時間	約 90 秒（人工翻查）	約 40 秒（全自動）	縮減 55.6%
故障代碼檢索準確率	基準值	基準值提升 30% 以上	提升 30% 以上
標準作業程序生成時間	不支援（需人工撰寫）	包含於 40 秒內	全新自動化能力
流程圖動態生成時間	不支援（需專業軟體）	包含於 40 秒內	全新自動化能力
工安合規	依維修人員經驗而定	硬性防線，100% 強制包含	達成零漏報與完全合規目標

7.2 混合重排序演算法效益驗證

在實際測試與系統調校過程中，當系統遇到設備型號非常接近的查詢（例如同一家廠商但不同系列的逆變器設備）時，傳統的純向量語意搜尋常因語意空間的距離太過接近，導致系統產生型號混淆與排名誤判的問題。

在導入本研究所設計的混合重排序演算法後，透過核心關鍵字的加權機制，系統能有效將完全符合目標型號與故障代碼的維修技術文件推升至檢索排名的最前端，顯著降低了排名噪聲。根據實驗數據驗證，在包含明確設備型號的查詢情境下，本系統的第一順位命中精準度較傳統純向量檢索提升了 30% 以上，充分證實了此混合重排序機制在工業維修精確檢索上，能有效克服相近型號的干擾，具備實質的優化效益。

7.3 RAGAS 評估結果品質分析

根據系統後台的遙測日誌數據顯示，本研究系統在品質評估指標上皆展現出優異的穩定性，具體結果分析如下：

- **防幻覺攔截成效(Groundedness)**：面對知識庫中完全不存在相關資訊的未知查詢時，系統設計的防幻覺截斷機制皆能成功攔截，直接拒絕生成不實內容，從根本上避免了大型語言模型因技術幻覺而輸出危險、不切實際的猜測性維修步驟。
- **扎實度與關聯性表現(Relevance)**：在知識庫內確實含有對應維修文件的查詢情境下，系統生成內容的「扎實度」與「關聯性」通過率均持續維持在高水準，證實本系統能提供精確且切中要點的技術回答。
- **工業安全合規性(Safety)**：在安全性評估方面，由於動態流程圖的程序骨架硬性要求必須包含上鎖掛牌的安全隔離節點，使得系統在工業安全合規性的通過率達到了 100%，有效落實了零漏報的安全防線。

7.4 實驗設置與評估方法

為了客觀測試我們設計的系統在太陽能設備維修時的檢索準確度、生成效能和工安防線，本研究規劃了一套標準的實驗流程 。主要分為測試資料集、對比基準（Baseline）和軟硬體環境三個部分：

- 測試資料集規模： 我們共收集並匯入了 10 份涵蓋太陽能逆變器、直流匯流箱等設備的技術手冊與工安規範 。經過多型態資料解析模組處理後，切分成 480 個標準文本區塊（Chunks）並寫入 ChromaDB 向量資料庫 。另外，針對現場容易搞混的故障代碼，我們人工標註了 30 組常見的故障 QA 測試對，用來當作系統檢索與生成的測試基準。
- 對比基準設定： 為了驗證我們提出的「雙層意圖分析」和「自定義混合重排序演算法」到底有沒有優化效果 ，我們實作了一套傳統的 RAG 系統當作對照組。這個 Baseline 系統使用和我們相同的 nomic-embed-text 嵌入模型與 llama3.2 主推理模型 ，但在檢索時只單純依賴向量相似度進行排序，不啟用任何 Metadata 過濾與關鍵字加權機制。
- 軟硬體測試環境： 為了確保完全本地化運行並保障企業資安 ，所有模型推理與 RAGAS 品質評估都在獨立的本地端裝置上執行 。硬體環境配置為 NVIDIA GeForce RTX 4060 GPU (32GB RAM)；軟體環境則是基於 Ollama 本地推理引擎、LangChain 框架與 Python 3.10 開發管線 。

第八章　結論與未來展望

8.1 研究成果結論

本專題成功打造一套完全於本地端運行的多模組協作太陽能設備維修智慧助手，實現了從使用者問題輸入到標準作業程序生成與流程圖動態渲染的端到端自動化。本系統在運維效能、檢索準確度與工業安全三個維度均達到預期之工程目標，具體研究成果總結如下：

- **運維檢索效率大幅躍升**：維修文件檢索與標準作業程序生成時間由原本人工翻查所需的 90 秒，大幅縮短至 40 秒，整體運維處置效率顯著提升 55.6%。
- **精確克服型號混淆限制**：研發之混合重排序演算法成功解決純向量搜尋的局限，有效壓制相近型號的排名雜訊，使易混淆故障代碼的第一順位檢索準確率提升 30% 以上。
- **工安防線達到完全合規**：導入硬性防幻覺截斷機制與上鎖掛牌工安程序骨架，藉由後端程式的硬性約束，從根本上確保系統達到零幻覺、零危險操作輸出的安全指標，工安合規率達到 100%。
- **建構自動化閉環迭代機制**：整合自動化品質評估代理，將詳細扣分原因與優化建議即時回饋至日誌系統，建立了能持續改善知識庫與系統配置的資料閉環。
- **完善保障企業資安隱私**：系統採用完全本地化部署架構，確保所有核心技術手冊與維修紀錄均不外流，全面保障資訊安全，極具企業敏感環境的實務應用價值。

8.2 技術貢獻

本研究在以下幾個技術層面具有實質貢獻：

1. **建構三層式精密檢索架構**：設計並驗證了適用於工業維修場景的「意圖攔截、元資料精確過濾、混合重排序」三層檢索架構，有效解決了傳統檢索增強生成系統在特定設備型號識別上的局限性，大幅提升了工業技術文件的檢索精準度。
2. **提出兩階段流程圖生成方案**：創新提出「大型語言模型萃取結構化資料結合程式語言動態渲染」的流程圖兩階段生成方案，完全消除了人工智慧模型直接生成圖表代碼時常發生的語法錯誤問題，為其他需要生成結構化視覺化內容的智慧系統提供了可複製的設計模式。

3. **首創工安標準硬性語意約束**：首次將上鎖掛牌工業安全標準融入大型語言模型生成流程的硬性骨架中，藉由後端程式的強大約束，確保系統生成的維修指引完全符合工安法規，為工業人工智慧應用的安全合規設計提供了極具價值的參考範本。

8.3 未來展望

基於本次學術專題之研究成果，本系統未來可於以下幾個關鍵技術維度進行深化研究與系統功能擴充：

- **多模態輸入之範疇擴充**：未來規劃整合設備故障圖片之輸入能力，導入視覺大型語言模型，容許現場維修人員直接拍攝並上傳故障現場之實體現象。系統隨即能自動識別影像特徵並比對地端知識庫，以提供更為直觀且精準之維修處置建議。
- **知識圖譜技術之深度整合**：於現有向量資料庫之檢索基礎上，進一步引入知識圖譜架構，建立各設備組件、廠牌與故障現象間之拓撲關聯關係。藉此支援更為複雜的多跳推理查詢，例如深入分析特定核心零件故障時，對整體系統運作所產生之連帶影響。
- **特定領域模型之自主微調**：持續蒐集更具規模且高質量的太陽能設備維修專業問答對數據集，針對基礎大型語言模型進行特定領域之微調，以進一步提升專業技術文本之生成品質，並有效降低系統對於檢索增強生成上下文長度之依賴。
- **主動學習閉環機制之建構**：基於自動化評估代理之遙測日誌數據，系統可自動識別並統計頻繁觸發「知識庫未命中」之異常問題類型，隨後主動向系統管理員推薦亟需補充之技術手冊或知識文件，實現知識庫之自動化擴充建議。
- **跨異質設備之通用性推廣**：將本系統之多模組協作架構推廣至風力發電機、儲能電池管理系統等其他再生能源設備，進一步打造範疇更為通用、強健之工業維修人工智慧平台。

參考文獻

[1] Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020.

[2] Es, S. et al. (2023). RAGAS: Automated Evaluation of Retrieval Augmented Generation. arXiv:2309.15217.

[3] Nomic AI (2024). nomic-embed-text: A Scalable Long Context English Embedding Model. arXiv:2402.01613.

[4] Chroma Research (2023). Chroma: the AI-native open-source embedding database. https://docs.trychroma.com

[5] IBM Documentation (2023). Lock Out Tag Out (LOTO) Safety Procedures. Industrial Safety Standards.

[6] LangChain Documentation (2024). LangChain: Building Applications with LLMs through Composability. https://docs.langchain.com

[7] Docling Team (2024). Docling: An Open-Source Document Conversion Toolkit. IBM Research.

[8] Gradio Team (2024). Gradio: Build and share delightful machine learning apps. https://www.gradio.app

[9] Meta AI (2024). LLaMA 3.2: Llama 3 Models. https://www.llama.com

[10] Google DeepMind (2024). Gemma: Open Models Based on Gemini Research and Technology.